

YOLOv8 Detection Pipeline

Detekcija klasa: marija i masa

1. Opis problema

Cilj projekta je razvoj sistema za automatsku detekciju osoba na slikama, pri čemu sistem treba da prepozna i razlikuje dve specifične osobe: klase marija i masa. Problem spada u domenu detekcije objekata (object detection) — za razliku od klasifikacije, sistem mora ne samo da prepozna klasu, već i da locira svaki objekat bounding box-om unutar slike.

Moguće situacije u projektu:

- Objekti se pojavljuju u različitim veličinama — od izuzetno malih (tiny, <1% površine slike) do krupnih kadrova
- Na pojedinim slikama prisutna su oba objekta istovremeno, što zahteva sposobnost višestruke detekcije
- Vizuelna sličnost između dve klase (dve osobe) povećava rizik od pogrešne klasifikacije
- Dataset je relativno mali (522 slike ukupno), što nameće ograničenja u pogledu generalizacije modela

2. Korišćeni podaci


2.1 Opis dataseta

Dataset je sopstveni dataset kreiran i anotiran u alatu Roboflow. Slike prikazuju dve osobe (klase marija i masa) u različitim uslovima snimanja — blizu i daleko, u unutrašnjim i spoljašnjim prostorima. Svaki objekat je anotiran bounding box-om koji obuhvata vidljivi deo objekta. Slike bez objekta korišćene su kao background primeri.

Podela dataseta:

Skup	Slike	Objekti	marija / masa	Medijana area bbox
Train	378	415	208 / 207	3.98% slike
Validation	69	70	35 / 35	6.93% slike
Test	75	80	40 / 40	5.98% slike

Raspodela klasa je potpuno balansirana u svim skupovima (50% / 50%), što eliminiše class imbalance kao potencijalni problem tokom treninga.



2.2 Analiza bounding box-ova

Jedna od ključnih karakteristika dataseta je dominacija malih i sitnih bounding box-ova, naročito u trening skupu. Ovo je direktno uticalo na odabir veličine ulazne slike (imgsz=640).

Kategorija	Train	Val	Test
Tiny (<1% slike)	76	6	13
Small (1–5% slike)	147	27	23
Medium (5–20% slike)	170	25	41
Large (>20% slike)	22	12	3

U trening skupu čak 76 bbox-ova (18.3%) spada u kategoriju tiny (<1% slike), što znači da su objekti izuzetno mali i teški za detekciju. Medijana površine bbox-a u trening skupu iznosi svega 3.98% slike, dok je u validacionom i test skupu nešto veća (6.93% i 5.98%), što ukazuje na to da trening skup sadrži relativno više teških primera.

2.3 Pravila anotacije

- Svaki vidljivi objekat koji pripada jednoj od dve klase označen je bounding box-om
- Box obuhvata vidljivi deo objekta
- Slike bez ijednog objekta korišćene su kao negativni primeri (background)
- YOLO koordinate su normalizovane u opsegu [0, 1]

2.4 Kontrola kvaliteta dataseta

Pre početka treninga u `train.py` implementirana je automatska provera kvaliteta dataseta koja verifikuje:

- Postojanje svih slika i odgovarajućih label fajlova
- Parovanje svake slike sa `.txt` fajlom koji sadrži anotacije
- Ispravnost YOLO koordinata — sve vrednosti moraju biti normalizovane u opsegu `[0, 1]`

3. Istraživane arhitekture

U okviru projekta razmatrano je više pristupa pre donošenja konačne odluke o arhitekturi:

Model	Prednosti	Mane / Razlog odbacivanja
YOLOv8n (pretrained)	Brz trening, dobra inicijalizacija	nije pogodan za specifičan sopstveni dataset, nije u skladu sa uslovima zadatka
YOLOv8n od nule (izabrano)	Potpuna kontrola	Duži trening, potrebno više epoha

4. Izabrano rešenje

4.1 Model i konfiguracija

Korišćena arhitektura: YOLOv8n (nano) — najmanji model iz YOLOv8 familije, pogodan za mali dataset i dve klase.

Ključni hiperparametri (`config.py`):

- `model_yaml = "yolov8n.yaml"` — arhitektura bez pretrained težina
- `train_from_scratch = True` — trening od nule
- `epochs = 200` — maksimalan broj epoha
- `imgsz = 640` — veća ulazna rezolucija zbog malih objekata
- `batch = 8` — veličina batch-a
- `patience = 40` — early stopping ako nema napretka 40 epoha

Veličina slike povećana je na 640x640 piksela kako bi se poboljšala detekcija malih i tiny objekata, kojih ima značajan broj u datasetu.

4.2 Struktura projekta


Projekat je organizovan u modularne Python fajlove:

- **Hiperparametri:** `config.py`

- **Statistika i vizualizacija dataseta:** dataset.py
- **Kreiranje i učitavanje YOLO modela:** model.py
- **Trening, validacija i quality check:** train.py
- **Evaluacija na test skupu i analiza grešaka:** evaluate.py


4.3 Tok treninga

Model je dostigao optimalne rezultate u periodu epoha 178–183, a do epohe 200 se stabilizovao bez značajnog daljeg napretka. Loss krive pokazuju zdravo treniranje: train loss konstantno pada, a val loss brzo opada i stabilizuje se posle oko 100–120 epoha. Ovo ukazuje da nema preobučavanja (overfitting-a).






Epoha 50



Epoha 180





Epoha 200

5. Metrike evaluacije

Za evaluaciju korišćene su standardne metrike za detekciju objekata:

- mAP50 — mean Average Precision na IoU pragu 0.50; osnovna metrika za detekciju.
- mAP50-95 — prosečan mAP po IoU pragovima od 0.50 do 0.95 (korak 0.05); strožija metrika koja meri preciznost lokalizacije.
- Precision — udeo tačnih pozitivnih detekcija od svih detekcija ($P = TP / (TP + FP)$).
- Recall — udeo pronađenih objekata od svih stvarnih objekata ($R = TP / (TP + FN)$).
- F1 — harmonijska sredina Precision i Recall vrednosti; balansirani pokazatelj performansi.

Evaluacija je izvedena zasebno na validacionom i test skupu. Za analizu grešaka korišćen je niski confidence prag ($\text{conf}=0.25$) kako bi se detektovalo što više potencijalnih grešaka. Za produkcijsku upotrebu preporučuje se $\text{conf} \approx 0.55\text{--}0.60$, što odgovara optimalnoj F1 vrednosti na F1-confidence krivoj (best threshold ≈ 0.588).



6. Rezultati

6.1 Ukupni rezultati



Skup	mAP50	mAP50-95	Precision	Recall / F1
Validation	0.8385	0.5843	0.7849	0.8143 / 0.7993
Test	0.8860	0.6200	0.8701	0.8603 / 0.8652

Model generalizuje bolje na test skupu nego na validacionom, što je pozitivan znak i ukazuje na dobru generalizaciju. Razlika između mAP50 i mAP50-95 je očekivana i tipična za modele trenirane na datasetu sa dosta malih objekata — model dobro detektuje objekte, ali precizna lokalizacija ($\text{IoU} > 0.75$) je teža za sitne bbox-ove.

6.2 Rezultati po klasama (Test skup)

Klasa	Precision	Recall	mAP50	mAP50-95
marija	0.888	0.796	0.842	0.608
masa	0.852	0.925	0.930	0.632

Klasa masa ima viši recall (0.925 vs 0.796), što znači da model retko propušta objekte klase masa. Klasa marija ima viši precision (0.888 vs 0.852), što znači da je model precizniji kada tvrdi da je pronašao marija. Obe klase imaju mAP50 iznad 0.84, što potvrđuje solidne performanse za oba cilja detekcije.



7. Analiza grešaka

7.1 Greške na validacionom skupu

Na validacionom skupu pronađene su greške na 34 od 69 slika ($\approx 49\%$), sa ukupno 49 prijavljenih grešaka:

Tip greške	Broj	Komentar
Višak detekcija (false positive)	35	Model vidi objekat gde ga nema — uzrok: prag $\text{conf}=0.25$ je prenizak
Promašen objekat (false negative)	9	Tipično za tiny bbox ($<1\%$ slike) — veoma mali objekti teški za detekciju
Pogrešna klasa	5	Model pomešao marija i masa — vizuelna sličnost između klasa

7.2 Uzroci grešaka

Višak detekcija (false positive — 35 grešaka)

Dominantna vrsta greške. Primarni uzrok je nizak confidence prag korišćen u analizi grešaka ($\text{error_conf_threshold}=0.25$). Na ovom pragu model prijavljuje detekcije sa niskom pouzdanošću koje bi bile filtrirane na višem pragu. F1-confidence kriva pokazuje da je optimalni prag ≈ 0.588 — podizanjem praga na $0.55\text{--}0.60$ broj lažnih detekcija značajno se smanjuje.

Promašeni objekti (false negative — 9 grešaka)

Tipično se javljaju za tiny bbox-ove ($<1\%$ površine slike). U trening skupu postoji 76 takvih primera, što je relativno malo za učenje detekcije izuzetno malih objekata. Potencijalno poboljšanje: dodavanje više slika sa sitnim objektima ili primena mosaic augmentacije sa fokusiranjem na male objekte.

Pogrešna klasa (5 grešaka)

Model je u manjem broju slučajeva pobrkao klase marija i masa. Uzrok je vizuelna sličnost između dve osobe u određenim kadrovima (slična odeća, osvetljenje, rastojanje od kamere). Potencijalno poboljšanje: proširivanje dataseta sa jasno distinktivnim primerima po klasama.

8. Zaključak

YOLOv8n model treniran od nule postigao je solidne rezultate za zadatak detekcije dve specifične osobe na sopstvenom datasetu. Ključni rezultati na test skupu su $\text{mAP50} = 0.886$ i $\text{F1} = 0.865$, što potvrđuje da je model naučio da pouzdano detektuje i razlikuje klase marija i masa.

Trening od nule pokazao se kao ispravan izbor za specifičan sopstveni dataset — model se potpuno prilagodio zadatku. Balansiran dataset i pažljivo postavljani hiperparametri doprineli su stabilnom treningu bez preobučavanja.

Glavni identificirani problemi su: prisustvo velikog broja tiny bbox-ova u trening skupu (potencijal za unapređenje), i optimizacija confidence praga za produkcijsku upotrebu (preporučeno 0.55–0.60 umesto 0.25). Oba problema su rešiva proširenjem dataseta i podešavanjem parametara evaluacije.